

实验报告：基于 MediaPipe 与 Skeleton Transformer 的羽毛球动作识别

2023101137彭天资

一、实验背景与目的

羽毛球击球动作（如正手高远球、反手网前球等）具有显著的动态时间序列特征。本实验旨在验证一种轻量化、高解释性的动作分类范式：利用 MediaPipe Pose 算法先行将视频帧降维提取为人体骨架关键点坐标，进而将动作识别转化为结构化的骨架时间序列建模任务。实验基于 Kaggle 的 badminton_stroke_video 数据集，自行搭建包含位置编码（Positional Encoding）和多头自注意力机制的轻量级 Transformer Encoder，完成 6 分类任务的模型训练与评估。

二、数据预处理与特征提取机制

视频数据处理的核心在于降维与时序对齐。在预处理阶段，我们利用 OpenCV 逐帧读取视频，并利用预训练的 MediaPipe 提取人体的 33 个空间关键点。每个关键点包含空间三维坐标 (x, y, z) 及其可见度得分，因此每帧图像被浓缩为一个 132 维的特征向量。

针对视频持续时间长短不一的问题，本实验采用线性插值重采样策略，将任意长度的视频骨架序列统一规整为 $T = 30$ 帧，并进行去均值中心化。最终，系统成功处理了 **735** 个有效视频样本，按 8:2 划分为训练集与测试集。


三、骨架序列 Transformer 模型架构

本实验构建的 Skeleton Transformer 摒弃了处理空间像素的视觉特征提取器，直接对高维序列进行自注意力计算。

- Linear Embedding**: 将每帧 132 维的原始坐标映射到 128 维的隐空间。
- Positional Encoding**: 注入正弦绝对位置编码，赋予骨架 Token 时间先后概念（引拍、击球、收拍的顺序）。
- Transformer Encoder**: 采用 2 层、4 头的自注意力机制跨越时间帧捕获动态变化。
- 分类池化**: 沿时间维度执行均值池化（Mean Pooling），将序列特征压缩为单一向量，经由 MLP 输出 6 分类概率。

四、训练结果与曲线分析


实验设定 Batch Size 为 32，采用 Adam 优化器（学习率 10^{-3} ），训练 30 个 Epoch。



曲线现象分析：从训练曲线可以看出，Training Loss 呈现出整体下降的趋势（从 1.8039 降至 1.6169），说明模型具备初步的拟合能力。然而，Test Accuracy 曲线在 16% 到 28% 之间剧烈震荡，最终收敛于 **27.89%**。

这种现象典型的反映了 Transformer 架构的“数据饥渴（Data-Hungry）”特性。由于 Transformer 缺乏 CNN 那样的局部归纳偏置（Inductive Bias），在训练样本极少（本实验仅有约 580 个训练样本）且训练周期较短（仅 30 个 Epoch）的情况下，模型极易陷入局部极小值或严重欠拟合，无法在少量数据中自发学到具有强泛化性的动作特征。

五、混淆矩阵与分类归因分析



分类瓶颈分析： 结合最终的分类报告（Classification Report）与混淆矩阵，可以发现模型的预测存在严重的偏差：

1. **类别遗漏：** 模型对 `forehand_clear`（正手高远球）和 `backhand_drive`（反手平抽）的预测次数为 0（Recall 为 0）。这导致了系统触发了 `UndefinedMetricWarning`。
2. **特征混淆：** 大量样本被错误地归类到了 `backhand_net_shot`（反手网前）或 `forehand_lift`（正手挑球）上。

产生这种现象的物理学原因在于，羽毛球击球动作在起手阶段极其相似（例如平抽与挑球的早期步伐和躯干姿态几乎一致）。由于我们仅提取了三维坐标，且重采样至仅有 30 帧，这可能导致击球瞬间（手腕与小臂的微小发力动作）的决定性高频特征在插值过程中被平滑或丢失，模型无法仅凭宏观躯干坐标区分微小的动作变种。

六、单样本推理与总结

实验最后针对 `demo_video.mp4` 进行了端到端的单样本推理，成功跑通流水线并输出：

Predicted class: `forehand_drive`

Confidence: 0.20

尽管最终预测的置信度较低（仅 20%），侧面印证了模型尚未完全收敛，但本次实验成功验证了“视频提取 -> 骨架降维 -> 序列分类”这一 Pipeline 的全栈连通性。未来，若要将此系统商业化落地，需要从三个维度进行优化：一是指数级扩充带标注的训练集（至万级别）；二是增加骨架序列的长度并引入骨架图卷积（GCN）以强化空间拓扑连接；三是适当引入预训练权重，降低模型从零开始学习空间几何关系的难度。